

摘 要

神经辐射场 (Neural Radiance Fields, NeRF) 在三维重建与新视角合成任务上取得了突破性进展, 但它通常依赖密集的视图输入, 数据采集门槛高, 限制了实际应用。稀疏视点下 NeRF 重建方法有效降低了数据采集门槛, 在数字文化遗产保护、自动驾驶等领域展现出重要应用前景。然而, 现有方法仍面临几何一致性差、高频细节丢失、渲染伪影及泛化能力弱等问题。针对上述问题, 本文面向稀疏视点的神经辐射场重建提出了一种优化方法, 主要工作如下:

提出了一种基于可信射线增广与神经全变分 (Neural Total Variation, NeuraTV) 的稀疏视点 NeRF 重建方法。该方法基于场景表面几何一致性构造可信射线, 并通过权重分布筛选剔除可能遮挡误导的样本来扩充训练数据, 从而强化网络对场景几何与外观的约束。同时, 该方法利用神经网络自微分特性, 引入了连续情形下的 NeuraTV 正则化方法, 对密度场的空间梯度施加稀疏性约束, 指导网络参数优化。相比于传统定义在规则网格上的离散全变分模型, 该方法更为直接灵活。实验结果表明, 该方法重建结果在保持高频信息的同时抑制了伪影的产生, 提升了重建质量。

本文提出了一种面向稀疏视点下神经辐射场重建的方法, 有效缓解了重建的几何一致性差、高频信息缺失、渲染存在伪影及泛化能力弱的问题, 为相关领域的实际应用提供了新方案, 推动了稀疏视点下新视角合成任务的发展。

关键词: 神经辐射场; 稀疏视点; 射线增广; NeuraTV

目 录

摘 要	I
第 2 章 相关理论基础	3
2.1 相机成像理论	3
2.2 神经辐射场理论	6
2.2.1 场景表示	6
2.2.2 体积渲染	7
2.3 扩散模型理论	8
2.4 本章小结	9
第 4 章 基于可信射线增广与 NeuraTV 的稀疏视点 NeRF 重建	10
4.1 方法概述	10
4.2 射线增广与置信度评估	11
4.3 正则项设计	14
4.4 数据实验与结果分析	15
4.4.1 实验设置	15
4.4.2 实验结果	16
4.4.3 消融实验	21
4.5 本章小结	23

第2章 相关理论基础

本章详细介绍了研究所涉及的相关理论基础。第一节简要概述了有关相机成像的理论，讲解了如何利用变换矩阵刻画相机成像的整个过程；第二节主要概述了神经辐射场的相关理论研究，主要包括神经辐射场的场景表示、体积渲染技术以及优化设计；第三节简单介绍了扩散模型的相关内容；在第四节对本章的内容进行了总结。

2.1 相机成像理论

神经辐射场重建依赖相机成像的几何与物理基础，理解三维空间与二维图像的映射关系，是掌握 NeRF 可微渲染与场景重建的关键。相机成像的核心是将三维空间点映射为二维图像点，主要涉及四个坐标系和三次坐标变换。

四个坐标系分别为：世界坐标系 $O_w - X_w Y_w Z_w$ ，用于描述场景中各点的真实位置，可人为安放；相机坐标系 $O_c - X_c Y_c Z_c$ ，与相机视角绑定， Z_c 轴与光轴重合，原点 O_c 位于相机光心；图像坐标系 $O - XY$ ，对应实际成像平面，是像素坐标的缩放基础；像素坐标系 $o - uv$ ，即数字图像的离散二维网格。三次变换分别为：世界坐标系到相机坐标系、相机坐标系到图像坐标系、图像坐标系到像素坐标系。

(1) 世界坐标系与相机坐标系

世界坐标系是描述静态场景的统一参考系，NeRF 学习的辐射场函数输入即为世界坐标；相机坐标系随相机位姿变化，其采样点需转换为世界坐标才能输入 NeRF 网络。两者转换为三维刚体变换（旋转+平移）：

对于世界坐标系下的任一点 $\mathbf{P}(X_w, Y_w, Z_w)$ 变换到相机坐标系下得到点 $\mathbf{P}_1(X_c, Y_c, Z_c)$ ，其具体转换对应数学关系为：

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \end{bmatrix} = \mathbf{R} \cdot \begin{bmatrix} X_w \\ Y_w \\ Z_w \end{bmatrix} + \mathbf{T}, \quad (2.1)$$

其中， $\mathbf{R}$ 为旋转矩阵（由 X, Y, Z 绕轴旋转矩阵叠加得到）， $\mathbf{T}$ 为平移向量。同理，根据上式也可以进一步得到从相机坐标系到世界坐标系的逆变换。

$$\begin{bmatrix} X_w \\ Y_w \\ Z_w \end{bmatrix} = \mathbf{R}^{-1} \cdot \left(\begin{bmatrix} X_c \\ Y_c \\ Z_c \end{bmatrix} - \mathbf{T} \right). \quad (2.2)$$

(2) 相机坐标系和图像坐标系




图 2.1 (a) 相机成像模型, (b) 相机成像模型中三维空间对应关系的二维平面表示。

相机坐标系到图像坐标系的转换, 遵循小孔成像^[47]的几何原理, 如图 2.1 (a) 是相机坐标系到图像坐标系转换的完整几何模型, 体现了实际相机成像中小孔成像的原理 (包含相机各部分、两个坐标系和投影关系)。如图 2.1 (b) 是小孔成像原理的一个简化示意图, 用来辅助理解 (a) 中相机成像的几何关系。相机坐标系下点 $P_1(X_c, Y_c, Z_c)$ 映射到成像平面坐标系上的点 $P_2(X, Y)$, 由相似三角形可得核心关系:

$$\frac{Z_c}{f} = \frac{X_c}{X} = \frac{Y_c}{Y}, \quad (2.3)$$

用矩阵表示为:

$$\begin{bmatrix} X \\ Y \\ 1 \end{bmatrix} = \frac{1}{Z_c} \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \cdot \begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix}, \quad (2.4)$$

这一过程完成了从 3D 到 2D 的降维映射, 是成像过程极具意义的关键一环。

(3) 图像坐标系和像素坐标系




图 2.2 图像坐标系到像素坐标系转换示意图。

图像坐标系下点 $\mathbf{P}_2(X, Y)$ 是连续的物理坐标，而像素坐标为离散网格坐标，转换为线性变换（尺度+原点偏移）。如图 2.2 所示，假设像素物理尺寸为 dx 和 dy ，图像坐标系原点在像素坐标系中的坐标为 (u_0, v_0) ，则：

$$\begin{cases} u = \frac{X}{dx} + u_0 \\ v = \frac{Y}{dy} + v_0 \end{cases}, \quad (2.5)$$

因此，图像坐标系到像素坐标系的转换可以通过矩阵表示为：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{dx} & 0 & u_0 \\ 0 & \frac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} X \\ Y \\ 1 \end{bmatrix}. \quad (2.6)$$


将上述三个变换合并，得到从世界坐标系到像素坐标系的完整变换为：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \frac{1}{Z_c} \begin{bmatrix} \frac{f}{dx} & 0 & u_0 & 0 \\ 0 & \frac{f}{dy} & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \cdot [\mathbf{R}|\mathbf{T}] \cdot \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} = \mathbf{K} \cdot [\mathbf{R}|\mathbf{T}] \cdot \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}, \quad (2.7)$$

其中， $\mathbf{K}$ 常被称为相机内参，旋转矩阵 $\mathbf{R}$ 和偏移向量 $\mathbf{T}$ 常被称为相机外参。

2.2 神经辐射场理论

2.2.1 场景表示


 图 2.3 神经辐射场场景表示流程图^[9]。

与体素、网格等传统离散几何表示不同，NeRF 以连续、隐式且可微的 5D 函数描述静态三维场景，实现二维图像到高保真三维场景的转换，其场景定义函数为：

$$F_\theta: (\mathbf{x}, \mathbf{d}) \mapsto (\mathbf{c}, \sigma), \quad (2.8)$$

其中， $\mathbf{x} = (x, y, z) \in \mathbb{R}^3$ 表示空间中任意一点的三维坐标； $\mathbf{d} = (\theta, \phi)$ 表示观察方向的俯仰角和偏航角；输出中的 $\sigma \in \mathbb{R}^+$ 是该点的体密度； $\mathbf{c} = (r, g, b) \in [0, 1]^3$ 是视图相关的颜色信息。体密度 σ 仅依赖于位置 $\mathbf{x}$ ，这确保了场景的几何结构在不同的视角下是一致的，是场景的固有物理属性。颜色同时依赖于位置 $\mathbf{x}$ 和观察方向 $\mathbf{d}$ ，这确保了场景在不同视角下观察到颜色的差异性，使得模型能够捕捉现实世界中普遍存在的非朗伯体效应，如镜面高光、金属反光、折射和半透明材质的颜色变化。

如图 2.3 所示，上述的连续 5D 函数是由多层感知机网络^[48] (Multi-Layer Perceptron, MLP) 近似实现的，MLP 作为万能函数逼近器，其权重 Θ 中编码了整个场景的信息。尽管神经网络采用了万能函数逼近器 MLP，但实验发现深度神经网络存在频谱偏差问题，网络倾向于学习低频信息，若直接让 MLP 学习原始输入的 5D 坐标，结果会过度平滑，丢失高频细节^[49]。因此在图 2.3 中，对网络输入位置坐标 $\mathbf{x}$ 和观察方向 $\mathbf{d}$ ，输入坐标会通过编码后输入进一个子网络，然后输出一个中间特征向量和标量体密度值 σ ，最后该特征向量与观察方向进行拼接再通过一个额外的全连接层输出 RGB 颜色 $\mathbf{c}$ 。

2.2.2 体积渲染

NeRF 本身不能直接输出图片，要生成从特定视角观察到的图像，必须通过体积渲染^[50]这一物理过程。对于从相机原点 $\mathbf{o}$ 出发、方向为 $\mathbf{d}$ 穿过任意像素的一条射线 $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ ，这一像素颜色 $C(\mathbf{r})$ 可以通过沿射线的积分计算：

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \cdot \sigma(\mathbf{r}(t)) \cdot \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt, \quad (2.9)$$

其中, $T(t) = \exp\left(-\int_{t_n}^t \sigma(\mathbf{r}(s)) ds\right)$ 称为累积透射率, 代表射线从最近点 t_n 成功传播

到最远点 t_f 而未碰到任何粒子的概率。

在实际运用中, 连续积分是通过分层采样的方式进行离散化估计的。具体而言, 将射线区间分为 N 段, 每段进行均匀随机采样点 t_i ,

$$t_i \sim \mathcal{U}\left[t_n + \frac{i-1}{N}(t_f - t_n), t_n + \frac{i}{N}(t_f - t_n)\right]. \quad (2.10)$$

根据输入的位置坐标 $\mathbf{x}$ 和观察方向 $\mathbf{d}$ 查询网络 F_θ 得到该点的 $(\mathbf{c}, \sigma)$, 然后进行累加求和得到最终像素点的颜色:

$$\widehat{C}(\mathbf{r}) = \sum_{i=1}^N T_i (1 - \exp(-\sigma_i \delta_i)) \mathbf{c}_i, \quad (2.11)$$

其中, $\delta_i = t_{i+1} - t_i$ 是相邻采样点间的距离, $T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right)$ 是离散化的累积透射率。

2.3 扩散模型理论

扩散模型是一种基于迭代的生成模型, 核心通过前向扩散过程(加噪)和反向去噪(生成)两个过程学习数据分布。从而实现数据生成。前向扩散过程是固定的马尔可夫链, 从真实数据样本 $\mathbf{x}_0 \sim q(\mathbf{x})$ 开始, 逐步添加高斯噪声, 经过 T 步后, 数据趋近于纯高斯噪声。前向过程可以表示为:

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \epsilon_{t-1}, \quad (2.12)$$

其中, $\mathbf{x}_t$ 表示在第 t 步添加噪声后的数据样本, $\epsilon_{t-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\alpha_t = 1 - \beta_t$, 序列 $\{\beta_t\}_{t=1}^T$ 控制噪声水平。借助重参数化技巧可以直接生成任意 t 步的噪声样本, 当 T 足够大时, $\mathbf{x}_T$ 服从单位高斯分布。

反向扩散过程是可学习的马尔可夫链, 从纯噪声数据 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发, 通过神经网络逐步去除噪声, 从当前噪声样本 $\mathbf{x}_t$ 中恢复 $\mathbf{x}_{t-1}$, 最终生成一个逼真的数据样本 $\mathbf{x}_0$ 。每步去噪过程服从高斯分布, 其参数由神经网络预测。

模型通过最大化对数似然的下界进行优化训练, 核心是借助 KL 散度^[51] (Kullback Leibler, KL) 衡量两个分布的接近程度, 最小化不同分布间的差异。训练目标可以简化为三种形式: 预测前向过程的后验均值 $\mu_q(\mathbf{x}_t, t)$ 、预测原始数据 $\mathbf{x}_0$ 、

预测加入的噪声 ϵ_θ :

$$\begin{aligned} \argmin_{\theta} L_{VLB} &\propto \argmin_{\theta} \frac{1}{2\sigma_q^2(t)} \|\mu_{\theta}(x_t, t) - \mu_q(x_t, t)\|_2^2 \\ &\propto \argmin_{\theta} \frac{1}{2\sigma_q^2(t)} \cdot \frac{\bar{\alpha}_{t-1}(1-\alpha_t)^2}{(1-\bar{\alpha}_t)^2} \|\hat{x}_{\theta}(x_t, t) - x_0\|_2^2 \\ &\propto \argmin_{\theta} \frac{1}{2\sigma_q^2(t)} \cdot \frac{(1-\alpha_t)^2}{\alpha_t(1-\bar{\alpha}_t)} \|\hat{\epsilon}_{\theta}(x_t, t) - \epsilon_0\|_2^2, \end{aligned} \quad (2.13)$$

其中, $\mu_{\theta}(x_t, t)$, $\hat{x}_{\theta}(x_t, t)$, $\hat{\epsilon}_{\theta}(x_t, t)$ 均是通过网络模型学习到的数据。

在稀疏视角的条件下, NeRF 常常因输入图像数量不足或视角覆盖不均而导致重建结果出现几何模糊、纹理缺失或伪影等问题。扩散模型在这一任务中扮演了“先验引擎”与“数据扩充器”的关键角色, 能够有效弥补视角缺失带来的信息不足, 显著提升重建质量与稳定性, 提升重建任务的完整性、真实性与鲁棒性, 成为推动少视角乃至单视角神经辐射场重建的重要技术助力。

2.4 本章小结

本章对稀疏视点下的神经辐射场重建的优化方法中使用的相关概念和理论进行了介绍。第一节从如何通过变换矩阵完整描述相机成像的几何过程, 重点介绍了相机成像的基本原理; 第二节深入探讨了神经辐射场的核心理论; 第三节概述了扩散模型的相关理论及核心理念。整体而言, 本章梳理了与研究工作密切相关的多领域理论基础, 为后续方法的设计与实现提供了必要的理论支撑。

第 4 章 基于可信射线增广与 NeuraTV 的稀疏视点 NeRF 重建

针对现有稀疏视点下 NeRF 重建的几何一致性差及重建结果中出现伪影的问题, 本章提出一种基于可信射线增广和 NeuraTV 正则化的重建方法。该方法基于已知视图的射线构造虚拟射线, 并设计相应的筛选机制, 有效扩充场景表示所需的训练数据, 增强几何一致性约束。此外, 利用网络的自微分属性, 本章还引入 NeuraTV 正则项, 在场景表面建立连续平滑性约束, 减少重建结果中的漂浮物等伪影。

4.1 方法概述




图 4.1 基于射线增广和 NeuraTV 正则的稀疏视图神经辐射场重建方法架构(*表示预训练)。

基于稀疏视点的 NeRF 重建面临的核心挑战在于, 有限的输入视图难以提供充分的几何与外观约束, 易导致模型过拟合, 进而产生几何扭曲、表面模糊及漂浮伪影等问题。为此, 本章提出了一种基于射线增广与神经全变分^[64] (Neural Total Variation, NeuraTV) 正则的神经辐射场优化框架。如图 4.1 展示了本章方法的整体流程, 对其主要方法步骤阐述如下: 首先, 给定原始稀疏的输入视图 $I_M (M = 1, 2, 3, \dots, 9)$ 及其相机参数 $P_M (M = 1, 2, 3, \dots, 9)$, 对每条原始射线 $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ 进行采样, 并利用 MLP 预测各采样点的颜色 $\mathbf{c}$ 体密度 σ ; 随后, 通过体渲染技术得到该射线 $\mathbf{r}(t)$ 穿过像素点的颜色:

$$\widehat{\mathbf{C}}_{\theta}(\mathbf{r}) = \sum_{i=1}^N T_i \left(1 - \exp(-\sigma_i \delta_i) \right) \mathbf{c}_i, \quad (4.1)$$

其中, $T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right)$ 表示沿光的累计不透明度, 即光线传播至第 i 点未击中任何其他粒子的概率; $\delta_i = t_{i-1} - t_i$ 表示相邻采样点之间的距离。通过比较渲染图像与真实图像之间的像素级差异, 计算渲染颜色 $\widehat{C}_\theta(\mathbf{r})$ 与真实颜色 $C(\mathbf{r})$ 的总平方误差构建 $\mathcal{L}_{\text{rgb}}$ 损失:

$$\mathcal{L}_{\text{rgb}} = \sum_{\mathbf{r} \in \mathcal{R}} \left\| \widehat{C}_\theta(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2, \quad (4.2)$$

其中, $\mathcal{R}$ 是每批光线的集合。

在此过程中, 根据累计不透明度 T_i 计算出每条射线上对密度权重 ω_i 贡献最大的关键采样点 $\mathbf{P}_m$ 。基于表面几何一致性假设, 以关键点 $\mathbf{P}_m$ 为中心构造球面, 最后以关键点与球面点连线构造虚拟射线; 再通过可见性阈值筛选, 剔除被遮挡或信息冗余的射线, 筛选后的射线将尽可能的收敛到与其原始射线相同的表面点, 进而对原始稀疏射线进行数据增广, 得到更多的训练数据。与其他构造虚拟射线的稀疏视点下 NeRF 重建方法^{[22][24][30]}相比, 本章的构造方式并非对原始射线的随机扰动, 而是基于场景确切的表面点, 虚拟射线可以共用原始射线表示的场景深度信息。

为进一步增强重建场景的几何一致性, 本章引入了连续情形下的 NeuraTV 正则项 $\mathcal{L}_{\text{NeuraTV}}$, 对密度场的空间梯度施加稀疏性约束, 指导网络参数优化。此外, 本章还借鉴了 MixNeRF^[27]的思想, 采用混合密度模型对射线颜色分布 $p(\mathbf{c}|\mathbf{r})$ 进行建模, 由于混合密度模型具有表示复杂分布的能力, MixNeRF 通过最小化负对数似然 $\mathcal{L}_{\text{NLL}}$, 在稀疏输入下有效学习了场景的密度分布。沿用了 DiffusioNeRF^[43]基于预训练扩散模型的颜色先验信息 ϵ_θ , 其可以利用在多个场景上学到的普遍规律来推断当前稀疏输入下未知区域的重建。整体损失函数由下述各项组成, 其梯度可表示为:

$$\nabla \mathcal{L} = \lambda_1 \nabla \mathcal{L}_{\text{rgb}} + \lambda_2 \nabla \mathcal{L}_{\text{NLL}} + \lambda_2 \nabla \mathcal{L}'_{\text{NLL}} + \lambda_3 \nabla \mathcal{L}_{\text{NeuraTV}} - \lambda_4 \epsilon_\theta \quad (4.3)$$

其中, $\lambda_i (i = 1, 2, 3, 4)$ 是各正则项的权重系数, 在实验中分别取值 $1 \cdot 10^{-7}$ 、 $1 \cdot 10^{-4}$ 、 $1 \cdot 10^{-4}$ 、 $1 \cdot 10^{-7}$; $\mathcal{L}_{\text{NLL}} = -\sum_{\mathbf{r} \in \mathcal{R}} \log p(\mathbf{c}|\mathbf{r})$ 是原始射线颜色分布的负对数似然; $\mathcal{L}'_{\text{NLL}} = -\sum_{\mathbf{r} \in \mathcal{R}} \log p(\mathbf{c}|\mathbf{r}')$ 是新增射线颜色分布的负对数似然。

4.2 射线增广与置信度评估

稀疏输入下, NeRF 面临的主要挑战在于观测约束不足, 容易导致几何与外观的过拟合。为此, 本节提出一种基于表面几何一致性的射线增广方法, 保证了虚拟射线与原始射线收敛到场景的同一表面点, 最终利用训练过程中逐渐收敛的场景几何生成多样的虚拟射线以增加训练数据, 并引入了基于虚拟射线与原始射线权重分布相似性的筛选机制剔除错误监督。

如图 4.2 所示, 本章射线增广提供的额外训练数据是基于原始输入射线得到的, 并且依赖于对场景表面点的初始预测, 这要求网络具备一定程度的训练基础, 若在网络完全没有训练的时候过早引入新增虚拟射线, 那么模型所预测的表面点将包含较大误差, 从而引入噪声, 干扰网络训练。因此, 本章选择在网络经过初步训练、损失曲线趋于稳定, 网络能够对场景表面提供相对可靠的预测时, 再引入基于现有稀疏视点的原始射线下的新增虚拟射线。




图 4.2 基于原始射线的射线增广方法示意图。

依据神经辐射场的渲染原理可知, 射线上第 i 个采样点的透明度可以表示为 $\alpha_i = 1 - \exp(-\sigma_i \delta_i)$, 由此可以得到射线上采样点的权重 $\omega_i = T_i \cdot \alpha_i$, 其中 $T_i = \prod_{j=1}^{i-1} (1 - \alpha_j)$ 是累计不透明度。因为采样点的权重 ω_i 反映了所在射线上的采样点对最终像素颜色的贡献程度, 所以可确定射线上权重最大的采样点, 并得到该采样点的索引 m , 代入射线 $\mathbf{r}(t)$ 就可以知道该索引对应的采样点 $\mathbf{P}_m$ 的位置坐标。如图 4.2 以相机光心 $\mathbf{o}$ 到点 $\mathbf{P}_m$ 的距离 $R = \|\mathbf{o} - \mathbf{P}_m\|$ 为半径, 以 $\mathbf{P}_m$ 为球心构造一个球面, 在该球面上采样一点作为虚拟射线的相机光心 $\mathbf{o}'$, 从而可以构造出穿过这一光心的虚拟射线 $\mathbf{r}'(t) = \mathbf{o}' + t\mathbf{d}'$, 虚拟相机光心 $\mathbf{o}'$ 的坐标由球面参数方程确定:

$$\begin{cases} x = R \sin \theta \cos \varphi \\ y = R \sin \theta \sin \varphi \\ z = R \cos \theta \end{cases} \quad (4.4)$$

其中, $\theta \sim U[0, \pi]$ 表示射线的俯仰角, $\varphi \sim U[0, 2\pi]$ 表示射线的偏航角。这种构造方式保证了所有虚拟相机光心到表面点 $\mathbf{P}_m$ 的距离相等, 即保证了深度的一致性。随着网络的持续训练, 模型的对场景的表达不断增强, 对表面点 $\mathbf{P}_m$ 的预测也愈加精确。无论是新增虚拟射线的光线选取球面上哪一点作为相机光心, 所有虚拟射线均聚焦于同一表面点, 并从多个角度对该点进行监督。

然而, 当从不同视角观察三维场景中的同一物点时, 部分视角可能会存在遮挡问题, 这时构造的虚拟射线可能会在提供误导性训练的同时导致重建质量下降。为

了解决这个问题，本章引入了基于詹森-香农散度^[65] (Jensen-Shannon Divergence, JSD) 的筛选方式，剔除误导训练的射线。JSD 散度用于比较原始射线与新增虚拟射线上采

样点权重分布 $p(\sigma|\mathbf{r})$ 的相似性，射线的权重分布定义为各采样点权重的归一化形式：

$$p(\sigma|\mathbf{r}) = \frac{\omega_i}{\sum_j \omega_j} = \frac{1 - \exp(-\sigma_i \delta_i)}{\sum_j 1 - \exp(-\sigma_j \delta_j)}, \quad (4.5)$$

给定原始射线 $\mathbf{r}(t)$ 的权重分布 $P = p(\sigma|\mathbf{r})$ 和新增虚拟射线 $\mathbf{r}'(t)$ 的权重分布 $Q = p(\sigma'|\mathbf{r}')$ ，JSD 散度定义为：

$$\text{JSD}(P||Q) = \frac{1}{2} D_{\text{KL}}(P||M) + \frac{1}{2} D_{\text{KL}}(Q||M), \quad (4.6)$$

其中, D_{KL} 表示计算 KL 散度, 即 $D_{\text{KL}}(P||Q) = \sum P \cdot \log P/Q$; $M = 1/2(P + Q)$ 。JSD 散度 是两个概率分布之间相似性或差异性的一种对称的、平滑的、有界的度量, 取值范围是 $[0, 1]$, 有效的克服了 KL 散度非对称且无界的缺点。当且仅当两个分布完全相同时, JSD 的值为 0; 当两个分布完全分离时, JSD 的值为 1, 因此, JSD 散度 数值计算非常稳定, 不会出现除以零或无穷大的情况。在实验中, 本章通过设定阈值为 0.02 来筛选出可用的虚拟射线。




图 4.3 不同权重分布的射线 JSD 散度比较。其中，横轴表示采样点索引，纵轴表示权重大小。

将两条射线采样点的权重分布离散化到相同的区间，利用 JSD 散度比较两个分布，尽管两条射线的权重分布整体上可能不会完全相似，但它们的峰值点位置应该保持基本一致。如图 4.3 所示，实验数据表明，在增加的虚拟射线中，使用 JSD 散度来比较原始射线的权重分布与虚拟射线的权重分布，并设定合理阈值，可以有效筛选出与原始射线分布相似的虚拟射线，从而剔除被遮挡的虚拟射线，为场景几何重建提供更可靠的监督信息。如果 JSD 值小于某个阈值，就认为虚拟射线与原始射线在权重分布上相似，以此筛选出未被遮挡的射线，辅助重建场景几何。

此外，由于混合密度模型具有表示复杂分布的能力，为进一步防止虚拟射线误导网络，本章借鉴 MixNeRF 的思想，采用混合密度模型对原始射线及虚拟射线的颜色分布进行建模，通过最小化负对数似然监督优化网络。

4.3 正则项设计

本章引入了一种基于连续神经域的全变差正则项 NeuraTV，旨在显式约束三维场景的几何的局部平滑性。自然场景在三维空间中具有内在的局部相关性，无论是几何表面还是外观属性，在微小邻域内通常是连续且缓慢变化的，彼此靠近的点相比距离较远的点更可能存在相似性。传统全变差正则项通常定义在离散网格（如图

像素) 上, 难以充分捕捉数据在任意方向上的局部相关性。相比之下, NeuraTV 将三维场景视为一个连续函数, 并以坐标作为网络输入, 通过在连续域中对采样点处的导数施加约束, 更准确地刻画场景在任意方向上的平滑性。具体而言, 令密度场函数为 $\sigma(t)$, NeuraTV 正则化方法直接计算密度场沿每个坐标轴方向的局部变化率, 对密度场的空间梯度进行惩罚, 从而鼓励三维空间中的平滑性。其具体形式为:

$$\mathcal{L}_{\text{NeuraTV}} = \sum_t^N \left(\left| \frac{\partial \sigma(t)}{\partial x} \right| + \left| \frac{\partial \sigma(t)}{\partial y} \right| + \left| \frac{\partial \sigma(t)}{\partial z} \right| \right), \quad (4.7)$$

其中, t 为三维空间中的采样点, N 为采样点总数。该正则项直接在密度场上施加约束, 而非间接作用于渲染结果, 从而更本质地引导场景几何的局部平滑性。得益于神经网络的连续表示能力, NeuraTV 可对任意分布的点进行梯度计算, 有效捕捉三维空间中各个方向的局部结构信息, 为稀疏视角下的神经辐射场重建提供了更强大且灵活的平滑先验。

为进一步提升新增虚拟射线重建的稳定性, 本章借鉴 MixNeRF^[27]的思想, 对网络结构进行了扩展, 在预测出采样点颜色和体密度后, 引入了一个额外的全连接层, 用于输出颜色的期望值、方差及全局不确定性因子。该模块基于混合密度模型对光线上的颜色分布 $p(\mathbf{c}|\mathbf{r})$ 进行建模, 将光线上的所有采样点视为构成该分布的混合分量。通过最小化负对数似然损失 $\mathcal{L}_{\text{NLL}}$, 模型能够量化每个采样点的不确定性, 从而在不确定区域实现自适应调整, 提升整体重建稳定性, 以免新增虚拟射线误导网络。具体而言, 光线 $\mathbf{r}(t)$ 上的颜色分布可表示为:

$$p(\mathbf{c}|\mathbf{r}) = \sum_{j=1}^N \pi_j \mathcal{F}(\mathbf{c}; \mu_j^c, \beta_j), \quad (4.8)$$

其中, j 表示光线上的第 j 个采样点, N 为采样点总数; $\pi_j = T_j (1 - \exp(-\sigma_j \delta_j)) / \left[\sum_{m=1}^M T_m (1 - \exp(-\sigma_m \delta_m)) \right]$ 是通过体密度推导的混合系数。每个混合分量 $\mathcal{F}(\mathbf{c}; \mu_j^c, \beta_j)$ 是拉普拉斯分布的概率密度函数, 其中 μ_j^c 表示颜色分布的位置参数, 用来控制分布的中心位置, β_j 是尺度参数, 值越小则分布越集中。

4.4 数据实验与结果分析

4.4.1 实验设置

本实验是在单卡 vGPU-48GB 上训练的, 同时配备 12.8 版本的 CUDA, 基于

python 3.8 环境, 采用了 Adam 优化器, 其学习率从 $2 \cdot 10^{-2}$ 指数衰减到 $2 \cdot 10^{-5}$, 网络总共进行了 35k 次迭代训练, 并在训练 3500 次损失函数趋于收敛的时候引入射线增广策略, 在训练迭代 5000 次的时候引入 NeuraTV 正则化。训练过程中随机对 4096 根光线进行采样, 每根光线采样的样本点个数为 128, 批次大小设置为 32。

在真实世界包含多个场景的 DTU 数据集^[60]和 LLFF 数据集^[68]进行了一系列综合实验评估所提方法。DTU 数据集包含 124 个以不同对象为中心的场景, 每个场景都包含 48 张不同视点的图像及相应相机参数。LLFF 数据集包含 8 个不同场景, 每个场景用手持相机捕获 20-62 张图像及相应的相机参数。为了评估本方法在稀疏视图下场景重建能力, 本节在 3 张视图及 9 张视图配置下进行了实验。对于每个测试场景等间隔随机选择作为输入, 剩余的作为测试视图。

对于定量结果评价指标, 本章选用峰值信噪比^[61] (Peak Signal to Noise Ratio, PSNR) 结构相似性^[62] (Structural Similarity, SSIM)、可学习感知图像块相似度^[63] (Learned Perceptual Image Patch Similarity, LPIPS), 以及参考 DiffusioNeRF^[43]方法统计了每个场景关于这三个指标的“平均”分数 $(10^{-\text{PSNR}/10} \cdot \sqrt{1 - \text{SSIM}} \cdot \text{LPIPS})^{1/3}$ 对本章提出的方法及其他相关方法进行定量评估。PSNR 计算的是渲染图像与原始真实图像之间的峰值信噪比, 是像素最大值与两幅图像像素均方误差的比值, 因为像素最大值和像素均方误差的数量级相差较大, 因此常常对 PSNR 的结果取对数, 结果越大越好。SSIM 用于度量图像之间的结构相似性, 基于人眼视觉系统的特性, 考虑亮度、对比度和结构等方面的差异, 其数值越高, 表示图像的质量越好, 与真实图像越相似。而 LPIPS 是通过预训练的深度神经网络 (如 VGG、AlexNet) 提取图像的特征表示, 然后计算这些特征之间的距离来衡量图像的感知相似性, 而非像素级别的相似性, LPIPS 的值越低, 表示两张图像越相似。

4.4.2 实验结果

为验证所提方法的有效性, 本章与经典方法 MixNeRF^[27]、FlipNeRF^[30]、FD-NeRF^[69]、DiffusioNeRF^[43]进行了定性和定量比较, 所有方法均在完全相同的输入视图下进行训练与测试。其中, MixNeRF 针对稀疏输入场景下新视角合成任务的改进核心思想是改变 NeRF 中沿射线颜色积分的确定性模型, 通过用混合密度模型来描述像素颜色, 并辅以基于可能性的训练和几何正则化实现了更优的几何重建; FlipNeRF 根据稀疏视点下的原始射线与模型实时估算的表面法线得到“翻转反射射线”作为额外的训练信号, 来帮助模型在数据有限的情况下, 更准确地学习场景的 3D 几何结构; FD-NeRF 是本工作的第三章所提方法。

具体实验中, 选取了真实场景 DTU 数据集和 LLFF 数据集分别在 3-view、9-view 的输入设定进行稀疏视点下神经辐射场重建任务。其中, 选取了 DTU 数据集的 scan63 和 scan41 两个典型场景, 这两个场景具有鲜明的颜色和复杂的几何纹理, 对稀疏视点下重建能力构成了严峻挑战; 对于 LLFF 数据集选取了 fern 和 room 两个场景。




图 4.4 在 3-view 输入条件下, 不同方法在 DTU 数据集 scan63 场景和 scan41 场景上的新视点重建效果展示。

从图 4.4 的新视角重建结果可以观察到, MixNeRF 方法重建的结果整体结构得以保持, 但在第一行 scan63 场景水果的表面纹理显得模糊且存在漂浮伪影, 特别是第二行 scan41 场景杯子的重建, 杯子边缘几何轮廓完全出错, 出现很多明显漂浮物。FlipNeRF 方法在杯子边缘区域表现优于 MixNeRF, 重建相对更准确, 漂浮伪影有明显减少, 但在复杂纹理的处理上仍存在一定的模糊和失真。DiffusioNeRF 方法的结果显示出一定的细节生成能力, 但引入了明显的不自然重建缺失。而本章所提方法在整体清晰度、细节保留上相对优于其他对比方法, 生成的图像更接近真实图像。

与上述设定一样, 但进一步增加稀疏视点输入数量, 由 3 个视点的输入增加为 9 个视点, 实验在中等稀疏的设定下评估了各方法的性能。相较于先前极端稀疏 (3-view) 的条件, 9-view 提供了更多的监督信号, 旨在检验各方法在数据量适度增加时能应对真实场景中复杂的几何、材质与光照挑战, 实现更精细化重建。




图 4.5 在 9-view 输入条件下, 不同方法在 DTU 数据集 scan63 场景和 scan41 场景上的新视点重建效果展示。

如图 4.5 所示, 展示了在 DTU 数据集的 scan63 和 scan41 两个场景上, 使用稀疏视点 (9-view) 输入进行新视角合成的可视化质量对比。所有方法都在相同的九张输入视图下训练, 并在相同的新视角下进行评估。MixNeRF 方法与 3-view 结果相比, 两个场景重建模糊现象得到了缓解, 但如图两个场景局部放大区域, 其在细节区域渲染结果仍存在伪影, 对场景轮廓恢复不完整; FlipNeRF 得益于更多视角的信息, 整体表现较好, 但第一行 scan63 场景背景部分重建缺失, 第二行 scan41 场景局部放大区域杯子纹理颜色重建出错; DiffusioNeRF 方法在两个场景上整体渲染结果较好, 但在局部放大区域场景边缘重建与真实图像相比不够锐利, 且在第二个场景中背景颜色渲染错误。而本章方法在整体清晰度、细节丰富度上更接近真实图像, 有效恢复了场景高频细节。

结合之前对可视化结果的分析, 本节还给出了定量数据指标比较结果, 如表 4.1 所示, 展示了不同方法在 DTU 数据集 scan63 场景和 scan41 场景上使用稀疏视点 (3/9-view) 进行神经辐射场重建新视点的定量结果, 其中, 加粗字体表示最优结果。由表 4.1 可以看出所有方法在 9-view 设置下的各项指标均显著优于其在 3-view 下的表现。在 scan63 和 scan41 两个场景下, 本章所提的方法均取得了最高的 PSNR 值, 表明其在像素级颜色精度上综合表现最优、最稳定。在 scan63 场景上, 本章方法同时取得了最高的 SSIM, 说明其重建图像的整体结构最接近真实。尽管在个别指标上未排第一, 但其各项指标均表现良好, 这与其可视化结果中清晰、细节丰富、几何准确的表现相吻合。

表 4.1 不同方法在 DTU 数据集 scan63 场景和 scan41 场景，稀疏视点 (3/9-view) 输入下的神经辐射场重建任务的定量指标比较。

Scene	Method	PSNR $\uparrow$		SSIM $\uparrow$		LPIPS $\downarrow$		Average $\downarrow$	
		3-view	9-view	3-view	9-view	3-view	9-view	3-view	9-view
scan63	MixNeRF[27]	15.23	25.13	0.781	0.926	0.320	0.162	0.164	0.051
	FlipNeRF[30]	18.34	25.29	0.872	0.877	0.242	0.236	0.108	0.062
	FD-NeRF[69]	20.92	25.15	0.855	0.907	0.293	0.213	0.096	0.061
	DiffusioNeRF[43]	16.80	25.46	0.808	0.950	0.300	0.154	0.140	0.046
	Ours	18.75	25.57	0.889	0.924	0.240	0.131	0.102	0.046
scan41	MixNeRF[27]	14.95	25.33	0.565	0.858	0.567	0.228	0.229	0.063
	FlipNeRF[30]	17.43	25.70	0.720	0.933	0.359	0.163	0.151	0.048
	FD-NeRF[69]	19.66	23.97	0.689	0.816	0.442	0.362	0.138	0.090
	DiffusioNeRF[43]	18.10	25.41	0.524	0.917	0.454	0.163	0.169	0.051
	Ours	18.91	26.07	0.705	0.918	0.353	0.109	0.135	0.043

对于 LLFF 数据集选取了 fern 和 room 两个场景，fern 场景为一个前景复杂、深度不一的多种植被场景，存在大量细微结构、自遮挡与复杂区域，而 room 场景是一个室内的环境，包含丰富高频纹理、几何细节，这两个场景具有鲜明的颜色信息和复杂的几何特点，对稀疏视角下重建能力也构成了严峻挑战。




图 4.6 在 3-view 输入条件下，不同方法在 LLFF 数据集 fern 场景和 room 场景上的新视点重建效果展示。

从图 4.6 重建可视化结果可以看出，所有方法都基本重建出了场景的整体轮廓。其中，在第一行 fern 场景中，MixNeRF 方法重建出了植物的基本形态，但叶片细节严重缺失，整体显得模糊且混乱；FlipNeRF 方法在叶片结构上相对于 MixNeRF 方法有轻微改善，但叶片轮廓依旧未能完整重建，整体效果与真实图像相比较差；DiffusioNeRF 方法试图生成更丰富的细节，但重建结果出现了错位，叶片形态重建明显有所扭曲；而本章方法在所有对比方法中均表现良好，渲染的叶片轮廓、结构

都更接近真实场景形态。在第二行 room 场景中，MixNeRF 方法重建整个场景相对模糊且存在漂浮伪影；FlipNeRF 方法在复杂几何重建较好，但在某些平面区域，如墙壁、桌面的重建有所不完整；DiffusioNeRF 方法整体重建未产生伪影，但细节重建缺失，如图中局部区域重建与真实区域相比，数据线重建明显不完整；而本章方法在局部方法区域重建优于 MixNeRF 方法和 DiffusioNeRF 方法，虽然略比 FlipNeRF 方法几何边界重建较逊色一点，但本章方法在墙壁、桌面区域重建得到了较大程度的保留，相对优于 FlipNeRF 方法。

沿用前述设定，我们将稀疏视角的输入数量从 3 个扩展到 9 个，在中等稀疏条件下评估各个方法的性能。与之前极端稀疏（3-view）的情况相比，9 个视角提供了更丰富的监督信息，目的在于检验数据量适度增长时，各方法能否应对真实场景中复杂的几何、材质和光照挑战，从而实现更精细的重建。




图 4.5 在 9-view 输入条件下，不同方法在 LLFF 数据集 fern 场景和 room 场景上的新视点重建效果展示。

如图 4.5 所示，在第一行 fern 场景中 MixNeRF 方法在 9-view 下与 3-view 结果相比，其重建的植物整体轮廓表现更好了，叶片轮廓模糊程度较 3-view 有所减轻，但半透明感及细节与真实图像相比依然缺失；FlipNeRF 方法表现与 MixNeRF 方法类似，整体形状重建表现更优，但在恢复植物的复杂结构方面收效甚微；DiffusioNeRF 方法在 9 张视图的输入下有效抑制了 3 张视图下的错位情况，整体重建完整，但在背景部分重建产生明显漂浮斑点；本章所提方法在叶片边缘和间隙，能观察到逼真的半透明效果与自然的光线衰减，前景植物与背景环境的空间分离明确且融合自然。此外，在第二行 room 场景中，虽然所选方法均较大程度的对室内场景进行了还原，但在局部放大区域 MixNeRF 方法、FlipNeRF 方法均未重建出白板上的黑色文字，DiffusioNeRF 方法重建出了部分信息，与真实局部区域图像相比，可以看出本章重建结果明显更接近真实图像。

结合之前对可视化结果的分析，本节还给出了定量数据指标比较结果，如表 4.2 所示，展示了不同方法在 LLFF 数据集 fern 场景和 room 场景上使用稀疏视点

(3/9-view) 进行神经辐射场重建新视点的定量结果, 其中, 加粗字体表示最优结果。在 fern 场景中, 本章所提的方法在 PSNR、SSIM、LPIPS 三项指标上均取得了最佳值。这标志着其在像素精度、结构相似性和感知质量上实现了一定的提升, 这直接对应了图 4.4 及图 4.5 可视化结果中叶片纹理的清晰重建。在 room 场景上, 本章所提的方法相比基线方法 DiffusioNeRF 及其他方法也取得了最佳的 PSNR 及 LPIPS 值, 表明本章所提方法的有效性。

表 4.2 不同方法在 LLFF 数据集 fern 场景和 room 场景, 稀疏视点 (3/9-view) 输入下的神经辐射场重建任务的定量指标比较。

Scene	Method	PSNR $\uparrow$		SSIM $\uparrow$		LPIPS $\downarrow$		Average $\downarrow$	
		3-view	9-view	3-view	9-view	3-view	9-view	3-view	9-view
fern	MixNeRF[27]	19.01	23.90	0.664	0.733	0.368	0.341	0.116	0.072
	FlipNeRF[30]	19.35	24.40	0.678	0.769	0.358	0.292	0.110	0.063
	DiffusioNeRF[43]	19.63	24.56	0.753	0.738	0.242	0.281	0.087	0.064
	Ours	20.52	25.03	0.813	0.830	0.181	0.232	0.067	0.050
room	MixNeRF[27]	21.67	24.78	0.806	0.887	0.317	0.239	0.075	0.045
	FlipNeRF[30]	21.99	24.52	0.811	0.891	0.306	0.202	0.072	0.043
	DiffusioNeRF[43]	21.71	24.99	0.793	0.886	0.306	0.243	0.075	0.044
	Ours	22.33	25.74	0.819	0.871	0.219	0.186	0.061	0.040

4.4.3 消融实验

由于本章方法是在 DiffusioNeRF 的基础上进行的, 为了验证本章所提方法的有效性, 本节进行了消融实验。实验结果如图 4.6 所示, 每一行表示不同的场景; 每一列表示不同实验方法重建的新视点图像, 其中, (a) 表示重建视点的真实图像; (b) 表示 DiffusioNeRF 方法重建的新视点图像; (c) 表示在 DiffusioNeRF 方法基础上, 本章提出射线增广来扩充训练数据这一创新点实验重建的新视点图像; (d) 表示在 DiffusioNeRF 方法基础上, 本章提出射线增广及施加 NeuraTV 正则化后 (即本章整体方法) 重建的新视点图像。如图 4.6 观察第二列及第三列实验结果可知, 射线增广在原始稀疏视角的基础上构造信息量更丰富的训练数据, 使得网络监督信息增加, 有助于恢复场景几何结构, 提升几何结构一致性与连贯性。如图 4.6 观察第三列及第四列实验结果可知, NeuraTV 正则项的加入能够抑制伪影并保留细节, 提升了局部纹理与边缘的重建质量 (如叶子、果皮纹理、毛绒细节、杯体花纹等)。定量分析如表 4.3 所示, 其中包含 DiffusioNeRF 方法重建的新视点图像、在

DiffusioNeRF 方法基础上本章提出射线增广方法重建的新视点图像及本章整体方法重建的新视点图像量化结果展示。




图 4.6 在不同场景数据下的消融实验可视化结果展示。

由表 4.3 可以看出在四个评价指标中本章的方法几乎均取得了最优的结果。评价指标的最佳结果可以表明, 通过可信射线增广和 NeuraTV 正则化训练得到的稀疏视点神经辐射场重建新视点, 获得了较为丰富的场景信息, 提高了重建质量。

表 4.3 在不同场景数据下的消融实验量化指标比较。

Scene	Method	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	Average $\downarrow$
		3-view			
fern	DiffusioNeRF[43]	19.63	0.753	0.242	0.109
	Ours(Full)	20.52	0.813	0.181	0.089
	Ours _{w/o} $\mathcal{L}_{\text{NeuraTV}}$	20.18	0.783	0.187	0.094
scan63	DiffusioNeRF[43]	16.80	0.808	0.300	0.140
	Ours(Full)	18.75	0.889	0.240	0.102
	Ours _{w/o} $\mathcal{L}_{\text{NeuraTV}}$	18.62	0.882	0.245	0.105
scan82	DiffusioNeRF[43]	18.39	0.661	0.432	0.154
	Ours(Full)	18.84	0.656	0.431	0.149
	Ours _{w/o} $\mathcal{L}_{\text{NeuraTV}}$	18.66	0.651	0.442	0.153
scan41	DiffusioNeRF[43]	18.10	0.624	0.454	0.163
	Ours(Full)	18.91	0.705	0.353	0.135
	Ours _{w/o} $\mathcal{L}_{\text{NeuraTV}}$	18.87	0.675	0.373	0.140

4.5 本章小结

本章围绕稀疏视点输入下神经辐射场重建存在的几何扭曲、表面模糊、细节丢失及重建结果存在伪影的问题,提出了一种基于可信射线增广和 NeuraTV 正则的方法。该方法基于对原始射线上权重最大的采样点构造虚拟球面,并以其为中心点构造球面生成虚拟射线,保证虚拟射线与原始射线即使整体上权重分布不完全相似,但它们的峰值点位置应该保持基本一致这一基本事实对虚拟射线进行筛选,并利用混合密度模型具有表示复杂分布的能力,对原始射线及虚拟射线的颜色分布进行建模,进一步防止虚拟射线误导网络。同时,利用神经网络的自微分特性,引入连续情形下的 NeuraTV 正则化方法,相比于传统定义在规则网格上的离散全变分,其直接通过对密度场的空间梯度施加稀疏性约束,更加灵活。在 DTU 和 LLFF 真实场景数据集上的实验表明,该方法能渲染出细节丰富的新视角图像,在保持高频信息的同时抑制了伪影的产生。定量指标与可视化结果得出结论说明,本方法的重建效果在一定程度上优于现有方法,实现了重建质量的提升。

